Robotik Manipülasyonda Verimli Etki Tahmini için Dürtüsel Sinir Ağları
Spiking Neural Networks for Efficient Effect Prediction in Robotic Manipulation

Ahmet Erdem Bulut, Fatih Doğangün, Serdar Bahar, Emre Uğur
Bilgisayar Mühendisliği
Boğaziçi Üniversitesi
İstanbul, Türkiye
{ahmet.bulut1, fatih.dogangun, serdar.bahar}@std.bogazici.edu.tr, emre.ugur@bogazici.edu.tr

***Özetçe* —Robotik manipülasyonda eylemlerin nesneler üzerindeki etkisini tahmin edebilmek, etkili eylem planlarının yapılabilmesinde önemli bir rol oynar. Bu tahminin düşük hesaplama maliyetiyle gerçekleştirilebilmesi, sistemlerin verimli kullanımı açısından önem taşır. Çok Katmanlı Sinir Ağı (ÇKSA) gibi geleneksel derin öğrenme mimarileri etki tahmini konusunda başarılı olsalar da çok sayıda çarpma işlemine dayanan yapıları nedeniyle yüksek hesaplama maliyeti gerektirmektedir. Bu çalışmada verimli bir etki tahmini gerçekleştirebilmek amacıyla Sızıntılı Birleştir-ve-Ateşle nöronlarına dayanan bir Dürtüsel Sinir Ağı (DSA) modeli önerilmektedir. Benzetim ortamından toplanan verilerle olay tabanlı DSA ve ÇKSA modelleri eğitilmiş olup DSA için farklı zaman adımı sayılarının başarı oranı ve hesaplama maliyeti üzerindeki etkisi incelenmiştir. Deneyler önerilen DSA modelinin 5 zaman adımlı versiyonunun ÇKSA ile benzer etki tahmini performansı gösterdiğini, toplam işlem sayısını düşürdüğünü göstermektedir.**

Anahtar Kelimeler—Dürtüsel Sinir Ağları, Robotik Manipülasyon, Etki Tahmini

***Abstract*—Predicting the effects of actions on objects in robotic manipulation plays an important role in making effective action plans. Performing this prediction with low computational cost is important for the efficient usage of these systems. Although conventional deep learning architectures such as Multi-Layer Perceptron (MLP) are successful in effect prediction, they require high computational cost due to their structures that rely on a large number of multiplication operations. In this study, a Spiking Neural Network (SNN) model based on Leaky Integrate-and-Fire neurons is proposed to perform an efficient effect prediction. Both event-based SNN and MLP are trained on data collected from a simulation environment, and the impact of different numbers of time steps on accuracy and computational cost is examined for the SNN. Experiments show that the proposed SNN model with 5 time steps achieves a similar effect prediction performance to the MLP, and reduces the total number of operations.**

Keywords—Spiking Neural Networks, Robotic Manipulation, Effect Prediction

I. GİRİŞ

Derin öğrenme modelleri, robotik manipülasyon problemlerinde başarılı sonuçlar vererek bu alanda yaygın bir biçimde kullanılmaktadır [1]. Bu alandaki önemli ihtiyaçlardan biri, bir eylemin nesne üzerindeki etkisini önceden tahmin edebilmektir [2], [3]. Özellikle itme temelli görevlerde, uygulanacak eylemin nesne üzerinde nasıl bir etki oluşturacağının tahmin edilebilmesi, robotun hedeflerine uygun eylemi seçebilmesi ve planlarını buna göre oluşturabilmesi açısından önemlidir [3]. Yakın zamandaki bir çalışmada [4] parametrik becerilerin etki modellerini öğrenerek arama tabanlı görev planlaması gerçekleştirilmiş ve etki tahmininin çok adımlı planlama için temel bir gereklilik olduğu gösterilmiştir. Başka bir çalışmada [5] eylem etkilerinin öğrenilerek çok adımlı planlama yapılması gösterilmiş, bir diğer çalışmada [6] ise eylemlerin nesneler üzerindeki etkileri öğrenilerek ayrık nesne kategorileri keşfedilmiş ve bu kategoriler sembolik planlama yapmak için kullanılmıştır. Çok Katmanlı Sinir Ağı (ÇKSA) gibi geleneksel derin öğrenme mimarileri bu tür problemlerde başarılı olsa da çok sayıda matris çarpımına dayanan yapıları yüksek hesaplama maliyetine ve dolayısıyla yüksek enerji tüketimine yol açmaktadır. Sınırlı enerji bütçesiyle çalışması gereken robotik sistemlerde bu durum önemli bir kısıt oluşturmaktadır.

Bu soruna yanıt olarak, biyolojik sinir sistemlerinden ilham alan Dürtüsel Sinir Ağları (DSA) geliştirilmiştir [7]. DSA, nöronlardan oluşur ve her bir nöron gelen uyarılara bağlı olarak kendi içinde bir membran potansiyeli biriktirir. Nöron, bu potansiyel belirli bir eşik değerini aştığında bağlı olduğu nöronlara aktarmak üzere bir dürtü üretir. Membran potansiyeli eşiğin altında kaldığında ise herhangi bir aktarım gerçekleşmez. Dolayısıyla DSA'larda nöronlar arası iletişim, sürekli değerler yerine ikili dürtü sinyalleriyle gerçekleşmektedir. Bu ikili iletişim, hesaplama maliyetini önemli ölçüde düşürür. Geleneksel sinir ağlarında her doğrusal katman, girdi ve çıktı sayısının çarpımı ile orantılı miktarda çarpma işlemi gerektirirken, DSA'larda dürtü değerleri yalnızca 0 ve 1 olabildiğinden katmanlar arası hesaplamalarda çarpma işlemi sayısı büyük oranda azalarak yerini ağırlıkların toplanmasına bırakır. Hesaplama yalnızca dürtü oluştuğunda yapıldığı için olay tabanlı bir yapı ortaya çıkar. Intel Loihi [8], IBM TrueNorth [9] gibi nöromorfik donanımlar bu avantajdan faydalanarak geleneksel donanımlara kıyasla önemli ölçüde enerji tasarrufu sağlamaktadır [10]. Ancak DSA'ların yaygınlaşmasının önündeki temel engellerden biri, dürtü fonksiyonunun türevlenememesi nedeniyle geleneksel geri yayılım algoritmalarının doğrudan

979-8-3195-1046-4/26/$31.00 ©2026 IEEE

uygulanamamasıdır. Bu sorunu aşmak için Denk Gradyan İnişi gibi yöntemler önerilmiştir [11]. DSA'ların kullanımında bir diğer zorluk ise nöron çıktılarının ikili olması sebebiyle sürekli değerlerin doğrudan temsil edilememesidir ve bu durum regresyon problemlerinde bilgi kaybına yol açabilmektedir [12].

DSA'ların robotik alandaki uygulamaları son yıllarda araştırılan konulardan biridir. Bu alandaki gelişmeleri ele alan çalışmalar DSA'ların hız, enerji verimliliği ve olay tabanlı hesaplama kabiliyetleri sayesinde robotik görevlerinde umut verici bir alternatif oluşturduğunu göstermektedir [13], [14]. Robot kontrolü ve pekiştirmeli öğrenme tabanlı çalışmalarda elde edilen sonuçlar bu potansiyeli desteklemektedir [15], [16]. Buna karşın, DSA'ların robotik manipülasyonda etki tahmini gibi sürekli çıktılar gerektiren problemlerde kullanımı henüz yeterince incelenmemiştir.

Bu çalışmada, farklı doğrultulardaki itme eylemlerinin nesne üzerindeki etkisini tahmin etmek amacıyla DSA tabanlı bir model öneriyoruz ve bu modeli eşdeğer mimaride bir ÇKSA ile karşılaştırıyoruz. Önerilen model, etki tahmin etme görevinde, ÇKSA ile kıyaslanabilir bir hata oranına ulaşırken toplam işlem sayısını önemli ölçüde azaltmaktadır. Bunun yanında, DSA'larda kritik bir parametre olan zaman adımı sayısının doğruluk ve hesaplama maliyeti arasındaki ödünleşimi gösterilmektedir.

II. YÖNTEM

A. Problem Tanımı

Bir robot kolunun eylemlerinin nesne üzerindeki etkisinin tahmini, bu çalışmada bir regresyon problemi olarak ele alınmıştır. Model girdisi, nesnenin başlangıç konumu (x_0, y_0) ile uygulanacak 4 farklı itme eyleminin bire bir kodlamasının birleşiminden oluşan 6 boyutlu bir vektördür: $\mathbf{X} = [x_0,\ y_0,\ a_0,\ a_1,\ a_2,\ a_3]$. Model çıktısı ise eylemin nesne üzerinde oluşturduğu yer değişimidir: $\hat{\mathbf{y}} = [\Delta x,\ \Delta y]$.

Nesnenin eylemin sonrası konumu, tahmin edilen etkinin başlangıç konumuna eklenmesiyle elde edilebilir. Doğrudan konum tahmini yerine etki tahmininin tercih edilmesinin sebebi, modelin eyleminin sonucunu başlangıç konumundan bağımsız biçimde öğrenmesinin ve genellenebilir temsiller sunmasının amaçlanmasıdır.

B. Çok Katmanlı Sinir Ağı (ÇKSA) ile Etki Tahmini

Temel karşılaştırma modeli olarak ÇKSA ile etki tahmini kullanılmıştır. Kullanılan mimari Şekil 1'de gösterilmektedir. 3 gizli katman ve 1 çıktı katmanından oluşan bir ÇKSA tanımlanmıştır. Girdi vektörü, her biri 256 nöron içeren üç gizli katmandan geçerek 2 nöronlu çıktı katmanına ulaşır. Çıktı katmanı dışında tüm katmanlarda aktivasyon fonksiyonu olarak ReLU kullanılmıştır.

C. Dürtüsel Sinir Ağı (DSA) ile Etki Tahmini

Şekil 1'de görüldüğü üzere, bu çalışmada etki tahmini için DSA mimarisi ÇKSA ile karşılaştırılabilecek şekilde tasarlanmıştır. ÇKSA mimarisinden farklı olarak DSA modeline katmanlar arası ReLU aktivasyonları yerine Sızıntılı Birleştir-ve-Ateşle (SBA) nöronları eklenmiştir. SBA nöronunda l katmanındaki i nöronu için membran potansiyeli, başlangıçta $U_{i,0}^{(l)} = 0$ olacak şekilde $t = 1, \ldots, T$ zaman adımları boyunca aşağıdaki şekilde güncellenir.

$$U_{i,t}^{(l)} = \beta \cdot U_{i,t-1}^{(l)} + I_{i,t}^{(l)} \tag{1}$$

Burada $U_{i,t}^{(l)}$, t anındaki membran potansiyeli, β sızıntı çarpanı, $I_{i,t}^{(l)}$ ise bu nörona gelen akımdır ve şu şekilde ifade edilir:

$$I_{i,t}^{(l)} = \sum_j W_{ij}^{(l)} s_{j,t}^{(l-1)} + b_i^{(l)} \tag{2}$$

Burada $W_{ij}^{(l)}$, $(l-1)$. katmandaki j nöronundan l. katmandaki i nöronuna bağlanan ağırlığı ifade etmektedir. $b_i^{(l)}$ ise ilgili nörona ait yanlılık terimidir.

Bu temel güncelleme, sızıntılı birikim davranışını ifade etmektedir. Ancak SBA modelinde membran potansiyeli belli bir eşik değerini (U_{thr}) aştığında nöron dürtü ($s_{i,t}^{(l)}$) üretir ve potansiyelini sıfırlar. Denklem 1, dürtü üretimi sonrasındaki sıfırlanma etkisini yansıtmamaktadır. Bu sebeple SBA modelinde kullanılan güncelleme denklemi, Denklem 1'e eklenecek bir dürtü çarpanı ile ifade edilir:

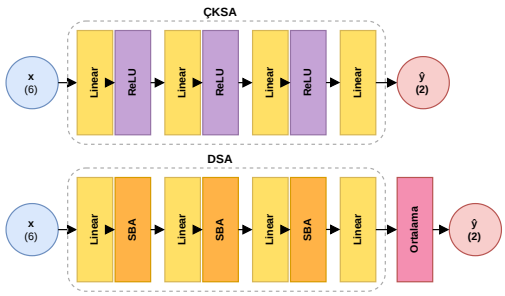
$$U_{i,t}^{(l)} = \beta \cdot U_{i,t-1}^{(l)} \cdot (1 - s_{i,t-1}^{(l)}) + I_{i,t}^{(l)} \tag{3}$$

$$s_{i,t}^{(l)} = \begin{cases} 1, & \text{if } U_{i,t}^{(l)} \geq U_{\text{thr}} \\ 0, & \text{if } U_{i,t}^{(l)} < U_{\text{thr}} \end{cases} \tag{4}$$

DSA mimarisinde ilk katman girdisi sürekli değerli olduğundan bir sonraki nöron katmanına aktarılacak akım ara katmanlardan farklı hesaplanır:

$$I_{i,t}^{(1)} = \sum_j W_{ij}^{(1)} x_j + b_i^{(1)}, \qquad t = 1, \ldots, T \tag{5}$$

DSA'larda girdi değeri x, tek seferlik bir ileri geçiş yerine T zaman adımı boyunca ağa yinelenen biçimde verilir ve her adımda nöronlar potansiyellerini güncelleyerek dürtü örüntüleri oluşturur. Buradaki zaman adımı sayısı, hesaplama maliyeti ve doğruluk arasındaki dengeyi belirleyen önemli bir etkendir. Daha fazla zaman adımı kullanmak modelin daha



Şekil 1: Çok Katmanlı Sinir Ağı ve Dürtüsel Sinir Ağları mimarileri

zengin dürtü örüntüleri yakalayıp daha iyi sonuç vermesini sağlayabilirken aynı zamanda hesaplama maliyetini doğrudan artırır.

Modelin son katmanında dürtü üretimi yerine, sürekli bir tahmin elde edilmesi için tüm zaman adımlarındaki akım çıktılarının ($I^{\text{Ç}}$) ortalaması alınır:

$$\hat{\mathbf{y}} = \frac{1}{T}\sum_{t=1}^{T} I_t^{\text{Ç}} \tag{6}$$

Bu tercih, ikili dürtü çıktılarının sürekli bir regresyon değerini doğrudan temsil edememesinden kaynaklanmaktadır. Geleneksel geri yayılım algoritmalarının kullanılamaması sorununu aşmak için Denk Gradyan İnişi [11] ve denk fonksiyon olarak hızlı sigmoit fonksiyonu kullanılmıştır. ÇKSA ile karşılaştırmak üzere DSA mimarisi de aynı katman boyutlarıyla kurulmuştur. Girdi vektörü, aynı şekilde 256 nörondan oluşan 3 gizli katmandan geçerek 2 nöronlu çıktı katmanına ulaşır. ÇKSA'dan farklı olarak katmanlar arasında ReLU aktivasyon fonksiyonu yerine SBA nöronları kullanılmıştır.

D. Dürtüsel Sinir Ağlarının Hesaplama Avantajı

DSA'ların hesaplama avantajı, ara katmanlardaki işlem yapısından kaynaklanır. Geleneksel sinir ağlarında her doğrusal katman, girdi ve çıktı boyutlarının çarpımı ile orantılı miktarda çarpma işlemi gerektirirken, DSA'larda dürtü değerleri ($s_{i,t}$, Denklem 4) yalnızca 0 ve 1 olabildiğinden çarpma işlemi sayısı büyük ölçüde azalır ve yalnızca dürtü üreten nöronlara karşılık gelen ağırlıklar toplanır. Dürtü üretmeyen nöronlar ise herhangi bir hesaplama gerektirmez. Katmanlardaki çarpım işlemleri sadece SBA nöronlarının membran potansiyellerini her zaman aralığında yenilemelerini simüle ederken kullandığımız formülden (Denklem 3) gelir.

III. DENEYLER

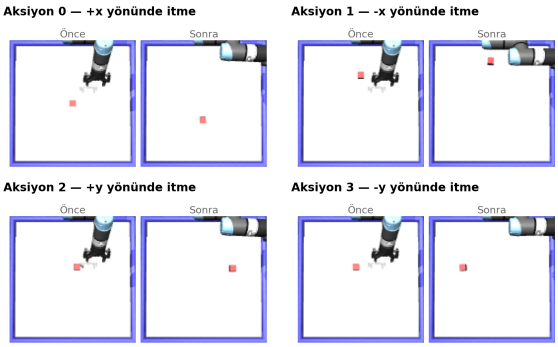
A. Deney Ortamı

Deneyler, MuJoCo [17] fizik benzetimci üzerinde çalışan bir robotik manipülasyon ortamında gerçekleştirilmiştir. Ortamda bir Universal Robots UR5e robot kolu, Robotiq 2F-85 tutucu ve sabit bir masa üzerinde yer alan $5\text{cm} \times 5\text{cm} \times 5\text{cm}$ boyutlarında bir küp bulunmaktadır. Ortamda robotun gerçekleştirebileceği 4 farklı itme eylemi tanımlanmıştır: Eylem 0, 1, 2 ve 3, sırasıyla ileriye itme, geriye çekme, sağa itme ve sola itme olarak tasarlanmıştır. Her eylem, ilgili itme hattı üzerinde sabit bir başlangıç ve bitiş noktası üzerinde gerçekleştirilmiştir.

Her eylemde robot kolu, belirli bir yol boyunca ilerleyerek küpe temas eder ve onu eylem yönünde iter. Her eylem sabit bir başlangıç ve bitiş noktası arasında tanımlı olup eylemlerin benzetim ortamında görselleştirilmesi Şekil 2'de verilmiştir.

Küpün başlangıç konumu, uygulanan eylemin itme doğrultusu üzerinde rastgele belirlenmektedir: Eylem 0 ve 1 için $x \in [0.4, 0.8], y = 0.0$; Eylem 2 ve 3 için ise $x = 0.6, y \in [-0.2, 0.2]$ koordinatları kullanılmıştır.

Ortamdan toplam 2000 örnek toplanmıştır. Her örnekte dört eylemden biri eşit olasılıkla seçilmiştir. Sonrasında nesne, ilgili eylemin itme hattı üzerinde rastgele bir noktaya yerleştirilmiştir. Nesnenin başlangıç pozisyonu kaydedildikten sonra seçilen



Şekil 2: Benzetim ortamındaki eylemlerin görselleştirilmesi

Model	Ort. Hata (cm)	<2.5cm (%)	<5cm (%)
ÇKSA	2.31 ± 0.09	75.7 ± 1.7	90.4 ± 0.4
DSA (T=1)	10.69 ± 3.84	15.5 ± 6.9	33.2 ± 15.4
DSA (T=2)	2.59 ± 0.10	67.9 ± 3.5	89.8 ± 0.8
DSA (T=5)	2.45 ± 0.20	71.7 ± 3.7	91.0 ± 1.0
DSA (T=10)	2.48 ± 0.06	70.7 ± 2.3	90.7 ± 1.3
DSA (T=20)	2.57 ± 0.07	69.4 ± 2.2	90.1 ± 0.3
DSA (T=50)	2.52 ± 0.09	70.7 ± 1.9	90.7 ± 1.1

TABLO I: Çok Katmanlı Sinir Ağı (ÇKSA) ve farklı zaman adımı (T) değerlerindeki Dürtüsel Sinir Ağları (DSA) modellerinin etki tahmini test sonuçları

eylem uygulanmış ve nesnenin son konumu kaydedilmiştir. Toplanan veri, %70 eğitim (1400), %15 doğrulama (300) ve %15 test (300) kümeleri olacak şekilde bölünmüştür.

B. Deney Sonuçları

Deneylerde ÇKSA modeline ek olarak altı farklı zaman adımı değeriyle ($T \in \{1, 2, 5, 10, 20, 50\}$) eğitilen DSA modelleri kullanılmıştır. Tüm modeller Adam optimizasyon algoritması, Ortalama Karesel Hata (OKH) kayıp fonksiyonu ve 0.0005 öğrenme çarpanı ile 200 epok boyunca eğitilmiştir. DSA modellerinde sızıntı çarpanı (β) 0.8 olarak belirlenmiştir. Mimarinin yazılımsal gerçeklemesi snnTorch [18] kütüphanesi kullanılarak yapılmıştır. Sonuçların güvenilirliğini sağlamak amacıyla tüm deneyler 5 farklı rastgele başlangıç tohumuyla tekrarlanmıştır.

1) Etki Tahmini: Modellerin etki tahmini performansı karşılaştırması Tablo I'de verilmiştir. Değerlendirme metriği olarak, tahmin edilen ve gerçek etki vektörleri arasındaki Öklidyen mesafenin ortalaması (Ort. Hata) kullanılmıştır. Buna ek olarak hatanın 2.5cm ve 5cm eşik değerlerinin altında kaldığı örneklerin oranları da raporlanmıştır.

Tablo I'de görüldüğü üzere $T = 1$ modeli yeterli bir dürtü örüntüsü oluşturamadığından yüksek hata oranları vermiştir. Diğer zaman adımı değerlerine karşılık gelen DSA modelleri ÇKSA'ya yakın hata değerlerine ulaşmıştır. En düşük ortalama hata $T = 5$ modelinde elde edilmiş olup $T = 10$ modeli benzer bir hata düzeyini daha düşük standart sapma ile sağlamıştır. $T = 10$ sonrasında zaman adımı sayısının artırılmasının hata oranında bir düşüş sağlamadığı fakat modellerin düşük bir değişkenlik ile daha stabil çalıştığı gözlemlenmiştir. Eşleşik t-testi sonuçlarına göre T=5 ve T=10 modelleri ile ÇKSA arasında etki tahmini bakımından istatistiksel olarak anlamlı bir fark bulunmamıştır (sırasıyla p=0.36, p=0.058).

Model	Çarpma	Toplama	Toplam işlem	ÇKSA'ya oranı
ÇKSA	133120	133120	266240	1.00×
DSA (T=1)	2304	∼3702	∼6006	0.02×
DSA (T=2)	4608	∼14309	∼18917	0.07×
DSA (T=5)	11520	∼49034	∼60554	0.23×
DSA (T=10)	23040	∼108372	∼131412	0.49×
DSA (T=20)	46080	∼218793	∼264873	0.99×
DSA (T=50)	115200	∼543988	∼659188	2.48×

TABLO II: Çok Katmanlı Sinir Ağı (ÇKSA) ve farklı zaman adımı (T) değerlerindeki Dürtüsel Sinir Ağları (DSA) modellerinin bir çıkarım için yapması gereken çarpma, toplama ve toplam işlem sayıları

2) İşlem Sayısı: Modellerin tek bir çıkarım sırasında yaptıkları işlemler Tablo II'de verilmiştir. ÇKSA modelinde işlem sayısı sabit kalırken DSA modellerinde verilen zaman adımına bağlı olarak işlem sayısı değişebilmektedir. DSA mimarisinde çarpma işlemleri ilk katman girdisinden ve membran potansiyelinin güncellendiği işlemlerden geldiği için sabittir. Ancak toplama işlemleri dürtü oranıyla bağlantılı olduğu için farklı tohum değerleri ile yapılan eğitimlerde farklılık gösterebilmektedir. Tablo II'de toplama işlemlerinin sayısı tüm tohum değerlerinde elde edilen işlem sayılarının ortalaması olarak raporlanmıştır. Raporlanan işlem sayısı değerleri DSA'nın olay tabanlı hesaplama prensibine dayanarak hesaplanmış değerlerdir.

İşlem verimliliği açısından değerlendirildiğinde, DSA (T=5) modeli ÇKSA ile benzer bir etki tahmin performansı sunarken toplam işlem sayısını ÇKSA'nın yaklaşık %23'üne düşürerek en iyi doğruluk ve hesap maliyeti dengesini sunmuştur. DSA (T=10) modeli benzer hata düzeyine ulaşsa da toplam işlem oranının yaklaşık %49'a çıkması verimliliğini azaltmıştır. Çarpma işlemi sayısı açısından bakıldığında DSA (T=5) ve DSA (T=10) modelleri bu sayıyı sırasıyla 11.6 ve 5.8 kat azaltmıştır.

IV. Sonuç

Bu çalışmada, robotik manipülasyonda önceden tanımlanmış eylemlerin etki tahmini için bir DSA modeli önerilmiş ve eşdeğer mimarideki bir ÇKSA ile karşılaştırılmıştır. Elde edilen sonuçlar, $T = 5$ zaman adımlı DSA modelinin etki tahmini görevinde ÇKSA ile kıyaslanabilir bir doğruluğa ulaşırken toplam işlem sayısını yaklaşık 4.4 kat dörtte birine, çarpma işlemi sayısını ise yaklaşık 11.6 kat azalttığını göstermektedir. Bu bulgu, DSA'ların robotik planlamada etki tahmini görevinde verimli bir alternatif oluşturabileceğine işaret etmektedir. Zaman adımı parametresinin etkisine yönelik analizler, $T \geq 10$ sonrasında doğrulukta bir düşüş olmadığını ortaya koymuştur. Bu durum, çalışmada anlatılan düzeydeki etki tahmini problemlerinde düşük zaman adımlarının yeterli bir dürtü örüntüsü oluşturabildiğini ve DSA'ların hesaplama avantajını ortaya çıkarabildiğini göstermektedir. Bu çalışmada, deneyler yalnızca benzetim ortamında gerçekleştirilmiş, hesaplama verimliliği teorik işlem sayılarına dayalı olarak değerlendirilmiş ve veri kümesi kısıtlı sayıda eylem tipi içerecek şekilde oluşturulmuştur. Gelecek çalışmalarda, önerilen modelin gerçek bir robot ortamında sınanması, eylem türlerinin çoğaltılması ve etki tahminlerinden faydalanarak daha karmaşık robotik manipülasyon problemlerinde çok adımlı planlama yapılması hedeflenmektedir.

Bilgilendirme

Bu çalışma, TÜBİTAK ARDEB 1001 programı (No: 124E227) ve AB tarafından finanse edilen INVERSE projesi (No: 101136067) tarafından desteklenmiştir.

Kaynaklar

[1] A. I. Károly, P. Galambos, J. Kuti, and I. J. Rudas, "Deep learning in robotics: Survey on model structures and training strategies," *IEEE Trans. Syst., Man, Cybern., Syst.*, vol. 51, no. 1, pp. 266–279, 2021.

[2] M. Y. Seker, A. E. Tekden, and E. Ugur, "Deep effect trajectory prediction in robot manipulation," *Rob. Auton. Syst.*, vol. 119, pp. 173–184, 2019.

[3] A. E. Tekden, A. Erdem, E. Erdem, T. Asfour, and E. Ugur, "Object and relation centric representations for push effect prediction," *Rob. Auton. Syst.*, vol. 174, p. 104632, 2024.

[4] J. Liang, M. Sharma, A. LaGrassa, S. Vats, S. Saxena, and O. Kroemer, "Search-based task planning with learned skill effect models for lifelong robotic manipulation," in *Proc. IEEE Int. Conf. Robot. Autom.*, 2022, pp. 6351–6357.

[5] H. Aktas, U. Bozdogan, and E. Ugur, "Multi-step planning with learned effects of partial action executions," *Adv. Robot.*, vol. 38, no. 8, pp. 562–576, 2024.

[6] A. Ahmetoglu, M. Y. Seker, J. Piater, E. Oztop, and E. Ugur, "DeepSym: Deep symbol generation and rule learning for planning from unsupervised robot interaction," *JAIR*, vol. 75, p. 709–745, 2022.

[7] W. Maass, "Networks of spiking neurons: The third generation of neural network models," *Neural Networks*, vol. 10, no. 9, pp. 1659–1671, 1997.

[8] M. Davies, N. Srinivasa, T.-H. Lin, G. Chinya, Y. Cao, S. H. Choday, G. Dimou, P. Joshi, N. Imam, S. Jain, Y. Liao, C.-K. Lin, A. Lines, R. Liu, D. Mathaikutty, S. McCoy, A. Paul, J. Tse, G. Venkataramanan, Y.-H. Weng, A. Wild, Y. Yang, and H. Wang, "Loihi: A neuromorphic manycore processor with on-chip learning," *IEEE Micro*, vol. 38, no. 1, pp. 82–99, 2018.

[9] P. A. Merolla, J. V. Arthur, R. Alvarez-Icaza, A. S. Cassidy, J. Sawada, F. Akopyan, B. L. Jackson, N. Imam, C. Guo, Y. Nakamura, B. Brezzo, I. Vo, S. K. Esser, R. Appuswamy, B. Taba, A. Amir, M. D. Flickner, W. P. Risk, R. Manohar, and D. S. Modha, "A million spiking-neuron integrated circuit with a scalable communication network and interface," *Science*, vol. 345, no. 6197, pp. 668–673, 2014.

[10] M. Rahimi Azghadi, C. Lammie, J. Eshraghian, M. Payvand, E. Donati, B. Linares-Barranco, and G. Indiveri, "Hardware implementation of deep network accelerators towards healthcare and biomedical applications," *IEEE Trans. Biomed. Circuits Syst.*, vol. PP, pp. 1–1, 2020.

[11] E. O. Neftci, H. Mostafa, and F. Zenke, "Surrogate gradient learning in spiking neural networks: Bringing the power of gradient-based optimization to spiking neural networks," *IEEE Signal Process. Mag.*, vol. 36, no. 6, pp. 51–63, 2019.

[12] A. Henkes, J. K. Eshraghian, and H. Wessels, "Spiking neural networks for nonlinear regression," *R. Soc. Open Sci.*, vol. 11, no. 5, p. 231606, 2024.

[13] Z. Bing, C. Meschede, F. Röhrbein, K. Huang, and A. C. Knoll, "A survey of robotics control based on learning-inspired spiking neural networks," *Front. Neurorobot.*, vol. 12, 2018.

[14] M. Aitsam, S. Davies, and A. Di Nuovo, "Neuromorphic computing for interactive robotics: A systematic review," *IEEE Access*, vol. 10, pp. 122 261–122 279, 2022.

[15] L. Zanatta, F. Barchi, S. Manoni, S. Tolu, A. Bartolini, and A. Acquaviva, "Exploring spiking neural networks for deep reinforcement learning in robotic tasks," *Sci. Rep.*, vol. 14, no. 1, p. 30648, 2024.

[16] C. Lee, Y. Park, S. Yoon, J. Lee, Y. Cho, and C. Park, "Brain-inspired learning rules for spiking neural network-based control: a tutorial," *Biomed. Eng. Lett.*, vol. 15, no. 1, pp. 37–55, 2025.

[17] E. Todorov, T. Erez, and Y. Tassa, "MuJoCo: A physics engine for model-based control," in *IEEE/RSJ IROS*, 2012, pp. 5026–5033.

[18] J. K. Eshraghian, M. Ward, E. O. Neftci, X. Wang, G. Lenz, G. Dwivedi, M. Bennamoun, D. S. Jeong, and W. D. Lu, "Training spiking neural networks using lessons from deep learning," *Proc. IEEE*, vol. 111, no. 9, pp. 1016–1054, 2023.